

냥 아레나 — 검토 결과 최종 취합 요청서

이 문서는 기록이다. 검토 취합을 지시하려고 쓴 것이고, 여기 인용된 수치는 그 시점의 것이다. 지금 수치는 `docs/generated/metrics-current.md` 가 매번 다시 재서 적는다.

이 문서는 여러 AI가 작성한 게임 검토 결과를 한 번 더 요약하기 위한 문서가 아니다. 원본 요청서, 실제 코드와 수치, 각 검토 의견을 대조해 **하나의 최종 판단과 먼저 실행할 실험 세 개**를 확정하기 위한 지시서다.

1. 함께 제공할 자료

가능한 자료를 다음 순서로 함께 제공한다.

- 원본 검토 요청서: `docs/review-brief.pdf` 또는 `docs/review-brief.md`
- 각 AI의 검토 답변 전문 — 검토 A, 검토 B 처럼 출처를 구분한다
- 화면 자료: `docs/shots/04-boss-avoid.png`, `docs/shots/05-boss-gather.png`, `docs/shots/06-boss-vulnerable.png`, `docs/shots/02-shop.png`
- 코드를 읽을 수 있다면 공개 저장소(<https://github.com/mmporong/nyang-arena>)와 플레이 주소(<https://mmporong.github.io/nyang-arena>)

자료가 일부 없으면 없는 범위를 명시하고, 확인하지 못한 내용을 사실처럼 단정하지 않는다.

2. 최우선 판정

가장 먼저 다음 질문에 답한다.

유물과 보스 개입이라는 깊은 축 두 개가 5분짜리 로그라이크 오토배틀러에 충분한가?

축의 개수만 세지 말고 다음을 구분한다.

- 전략적 깊이:** 상황에 따라 최선의 선택이 달라지고, 반복해도 판단이 남는다
- 지식 시험:** 정답을 한 번 배우면 이후에는 같은 선택을 반복한다
- 실행 숙련:** 신호를 읽고 정확한 타이밍에 반응하는 능력이다
- 폭:** 그 축을 아예 쓰지 않는 것보다 쓰는 편이 좋다
- 깊이:** 축을 생각 없이 쓰는 것보다 상황에 맞게 잘 쓰는 편이 좋다

먼저 이 판정을 내린 다음에 6절의 나머지 질문을 판단한다. 다른 답변을 먼저 정한 뒤 핵심 판정을 거꾸로 끼워 맞추지 않는다.

3. 검토 원칙

너는 검토 결과의 요약자가 아니라 **최종 판정자**다.

- 검토자 수를 세어 다수결하지 않는다.

- 여러 검토자가 동의해도 원문·코드·측정 근거가 없으면 채택하지 않는다.
- 사실, 근거에서 나온 추론, 아직 모르는 것을 분리한다.
- 시뮬레이션이 증명할 수 있는 생존·정책 격차와, 사람 실험이 필요한 재미·인지·재진입을 구분한다.
- 새로운 기능보다 삭제, 기존 규칙의 결합, 측정 가능한 작은 변형을 먼저 검토한다.
- 제안을 채택할 때는 반드시 그 제안을 기각할 수도 있는 실험을 함께 제시한다.
- “더 재미있을 것 같다”는 이유만으로 채택하지 않는다.

서로 충돌하는 검토 의견은 어느 쪽이 더 그럴듯한지만 말하지 말고, **어떤 관측값이 나오면 어느 쪽이 맞는지** 판별 기준을 적는다.

4. 코드와 측정에서 반드시 확인할 것

코드를 읽을 수 있다면 다음 주장을 직접 확인한다. 아래 문장을 사실로 가정하지 말고, 실제 구현과 출력이 맞는지 검증한다.

1. `scripts/placement-space.mjs` 의 합격 기준이 최선과 자동 배치의 **깊이**가 아니라 최선과 고의적 최악의 **폭**을 재고 있지 않은가
2. `scripts/intervention-space.mjs` 가 한 런의 여러 보스 시도를 합쳐 통과율을 계산하면서 반복 측정의 군집과 후반 생존자 편향을 만들지 않는가
3. 구매 실험이 가격·직업 물빵만 비교하고, 다음 보스와 현재 유물을 읽는 **로스터 교체·피벗**을 측정하지 않은 것은 아닌가
4. `scripts/balance-sweep.mjs` 가 `newRun()` 에 고정 시드를 전달하지 않아 동일 시드 A/B에 사용할 수 없는 것은 아닌가
5. 생성 지표가 특정 커밋만으로 재현되는 깨끗한 기준선인지, 작업 트리 변경이 섞인 산출물인지
6. 유물의 최고 정책이 상황에 따라 달라지는지, 아니면 한 고정 물빵 정책이 대부분의 상태에서 지배하는지
7. 취약 창이 실제 선택인지, 비용 없이 열릴 때마다 연타하는 단일 정답인지

코드를 볼 수 없다면 이 항목들은 **확인 필요**로 남기고, 검토자의 주장을 그대로 승인하지 않는다.

5. 6절 질문 7개의 최종 답변 형식

`docs/review-brief` 6절의 질문 7개에 빠짐없이 답한다. 각 항목은 아래 형식을 지킨다.

6-N. 질문 제목

- **최종 판정**: 한 문장
- **채택할 제안**: 실제로 남길 방향
- **버릴 제안**: 하지 않을 방향과 이유
- **근거**: 원문 수치, 코드, 검토 의견 중 판정을 지지하는 것
- **불확실성**: 현재 자료로는 결정할 수 없는 것
- **확인 실험**: 가설, 비교 조건, 지표, 성공·기각 기준

특히 다음 선택을 명확히 한다.

- 6-1: 넓히기 / 파기 / 접기 중 무엇을 어떤 순서로 할지
- 6-2: 취약 창을 강화 / 보상 연출로 유지 / 자원 선택으로 변경할지
- 6-3: 일반 웨이브를 유지 / 축소 / 성과 검증 구간으로 바꿀지
- 6-4: 지도를 살리기 위한 마지막 실험과 삭제 기준
- 6-5: 영구 파워 해금 없이 재진입을 만드는 방법
- 6-6: 목표 판 길이와 그것을 고르는 사람 실험
- 6-7: 아직 측정하지 않은 기존 결정 또는 새 축 후보

6. 가장 먼저 할 실험은 세 개만

검토 결과에서 나온 모든 아이디어를 백로그로 나열하지 않는다. 정보 가치가 가장 높은 실험 세 개만 선정하고 아래 표로 작성한다.

항목	작성 내용
검증할 가설	이 실험이 참과 거짓을 가를 문장
A/B 조건	비교할 정책 또는 규칙 변형
고정 변수	실험 중 바꾸지 않을 구매·배치·개입·시드 조건
1차 지표	최종 판정을 내릴 단 하나의 주 지표
가드레일	다른 깊은 축, 전체 난이도, 판 길이가 무너지지 않는 조건
채택 기준	효과와 불확실성이 어느 수준이면 채택하는가
기각 기준	어느 수준이면 미련 없이 버리는가
보류 기준	표본이나 효과가 애매할 때 어떻게 처리하는가
필요한 계측	현재 스크립트 재사용 여부와 새로 기록할 원시 값
예상 비용	구현·측정·되돌리기 비용의 상대적 크기

첫 실험 묶음은 최대 세 개다. 한 실험이 다음 실험의 전제를 결정한다면 순차 실행으로 표시한다.

7. 공통 실험 계약

시뮬레이션 제안에는 다음 기준을 기본으로 적용한다.

- 같은 시드 범위를 각 조건에 사용한다.
- 집계표뿐 아니라 **시드별 원시 결과**를 남긴다.
- 시드 1~300에서 후보를 찾았다면 301~600 같은 홀드아웃에서 다시 확인한다.
- 도달 웨이브는 시드별 paired 차이를 보고, 보스는 첫째·둘째처럼 고정된 기회를 따로 비교한다.

- 여러 보스 시도를 독립표본처럼 단순 합산하지 않는다.
- 평균이나 중앙값 하나만 보지 말고 95% 신뢰구간 또는 시드 단위 bootstrap 결과를 함께 제시한다.
- 여러 정책 중 가장 잘 나온 것을 사후 선택했다면 홀드아웃에서 재검증한다.
- 성공·기각·보류 기준을 결과를 보기 전에 정한다.

재미, 신호 판독성, 피로도, 즉시 재시작률과 다음 날 재방문은 봇 시뮬레이션으로 확정하지 않는다. 이 항목은 사람 실험의 표본, 과제, 행동 지표와 실패 기준을 별도로 제시한다.

8. 최종 출력

최종 답변은 다음 순서로 작성한다.

1. **핵심 판정** - 깊은 축 두 개가 충분한지 한 문장 - 현재 가장 큰 문제 한 문장 - 권장 방향을 **넓히기 / 파기 / 접기** 또는 그 조합으로 명시
2. **검토 결과 비교** - 합의된 주장 - 충돌하는 주장과 승패를 가를 근거 - 근거가 약해 보류할 주장 - 기각할 주장
3. **6절 질문 7개의 최종 답변**
4. **가장 먼저 할 실험 세 개**
5. **최종 분류** - 지금 실행 - 실험 후 결정 - 보류 - 제거

마지막에는 구현자가 추가 결정을 하지 않아도 되도록 첫 실험 세 개의 순서와 중단 조건을 명확히 적는다. 결론을 내릴 증거가 부족하면 억지로 합의하지 말고, 그 불확실성을 가장 싸게 줄이는 실험을 첫 순서에 둔다.